

Proyecto final - Egresos del Sector Público

Series Cronológicas, 2024

Ignacio Campón



FACULTAD DE
CIENCIAS ECONÓMICAS
Y DE ADMINISTRACIÓN

IESTA 80

INSTITUTO
DE ESTADÍSTICA



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY

Resumen Ejecutivo

Este trabajo busca el estudio de identificación, estimación y predicción de una serie de tiempo. Se analizan los **Egresos Primarios del Sector Público no Monetario** en Uruguay, entre enero de 1999 y abril de 2024. La serie de tiempo mensual, proporcionada por el [Ministerio de Economía y Finanzas](#), es fundamental para comprender la dinámica fiscal del país y anticipar tendencias futuras en base a modelos estadísticos. Siguiendo la metodología de Box y Jenkins, se busca identificar un modelo SARIMA a partir de la función de autocorrelación y autocorrelación parcial. Los modelos propuestos son puestos a prueba a través de una etapa de diagnóstico obteniendo un modelo final con el cual es realizada la predicción. Para esta se dividen los datos en conjuntos de entrenamiento y prueba a efectos de validar el modelo.

Índice

Resumen Ejecutivo	2
1 Introducción	4
1.1 Análisis Exploratorio	4
2 Metodología	6
2.1 Identificación del modelo	6
2.1.1 Pasos a seguir	8
2.1.2 Test de raíces unitarias	8
2.2 Estimación del modelo	12
2.3 Diagnóstico	14
2.4 Predicción	16
3 Comentarios Finales	19
Referencias	20
Apéndice	20

1 Introducción

En el contexto del análisis económico y financiero, los **Egresos Primarios del Sector Público no Monetario**, son una fuente crucial de información proporcionada por el [Ministerio de Economía y Finanzas](#). Esta serie mensual, ofrece una panorámica detallada de los desembolsos financieros del sector público, excluyendo transacciones monetarias, a lo largo del tiempo.

Los egresos primarios del sector público son fundamentales para entender la dinámica fiscal de un país, ya que representan los gastos esenciales en bienes y servicios no financieros realizados por el gobierno. Estos datos son vitales para analizar la gestión presupuestaria, evaluar políticas económicas y anticipar tendencias futuras en base a modelos estadísticos. En este informe, se explorará la serie temporal con el objetivo de identificar un modelo adecuado que permita reproducirla con precisión, facilitando así la capacidad predictiva sobre los egresos del sector público en Uruguay.

1.1 Análisis Exploratorio

La serie de Egresos Primarios del Sector Público no Monetario, abarca el período comprendido entre enero de 1999 y abril de 2024. Véase la figura 1. A lo largo de los años, se observa un crecimiento sostenido en los desembolsos del sector público, con fluctuaciones estacionales y ciertas tendencias a lo largo del tiempo. La serie presenta una tendencia creciente, con una estacionalidad marcada por picos y valles en determinados puntos lo cual destaca una no estacionariedad en la serie.




Figura 1: Evolución del Gasto Público mensual en millones de pesos corrientes entre enero 1999 y abril 2024.

Estos patrones sugieren la presencia de componentes estacionales. La figura 2 muestra el comportamiento mensual del Gasto Público entre 1999 y 2024. Se observa una clara estacionalidad en la serie, los picos y valles que se ven en la figura 1, han de corresponderse a los meses de diciembre y abril respectivamente. La diferencia en las medias son notorias para los meses mencionados, siendo los puntos donde se alcanza el máximo (diciembre) y mínimo (abril) en promedio. Esto sugiere una estacionalidad anual, la cual será un factor importante a considerar en el modelado de la serie.




Figura 2: Comportamiento mensual del Gasto Público entre 1999 y 2024.

La figura 3 muestra el comportamiento por año del Gasto Público entre 1999 y 2024. En esta figura puede verse con mayor claridad como se repiten los patrones año a año, lo cual, confirma la estacionalidad resaltada en la figura anterior.




Figura 3: Comportamiento por año del Gasto Público entre 1999 y 2024.

2 Metodología

El desarrollo de este trabajo esta basado en la metodología de Box y Jenkins, en la construcción de modelos ARIMA para el análisis de series de tiempo. Podemos dividir esta metodología en cuatro grandes etapas, identificación, estimación, diagnostico y predicción. En la identificación del modelo, consideraremos posibles transformaciones en los datos, evaluaremos la aplicación de ciertos filtros con el objetivo de obtener una serie estacional, con el uso de funciones de autocorrelación y autocorrelación parcial, criterios de información, diferentes test de raíces unitarias podremos obtener diferentes modelos candidatos. Tras la estimación, un diagnostico con determinadas etapas es realizado; y por último, aplicaremos predicciones sobre los mismos y se evaluará su desempeño.

2.1 Identificación del modelo

La transformación logarítmica de la serie, permite una homogenización de la varianza y una mejor visualización de la tendencia. La figura 4 muestra la evolución del logaritmo del Gasto Público entre 1999 y 2024, que a diferencia de la serie original (figura 1), presenta una tendencia más estable y menos volátil.




Figura 4: Evolución del logaritmo del Gasto Público mensual entre 1999 y 2024.

Obsérvese el autocorrelograma y el autocorrelograma parcial de la serie en la figura 5. En la función de autocorrelación (FAC), se observa una correlación significativa en los primeros rezagos, lo cual sugiere la presencia de una tendencia en la serie, concluyendo que se esta frente a una serie no estacionaria.




Figura 5: Funciones de Autocorrelación y Autocorrelación Parcial estimadas del logaritmo del Gasto Público.

2.1.1 Pasos a seguir

Para modelar la tendencia podemos utilizar dos caminos alternativos:

- **Considerar una tendencia determinística TS**, esto implica considerar una tasa de crecimiento, δ , constante en el tiempo, reemplazando la media del proceso estacionario como una función lineal del tiempo.
- **Considerar un proceso de raíz unitaria DS**, esto implica determinar si existe una raíz unitaria en el polinomio autoregresivo, en caso que así sea, se debe de aplicar diferencias regulares en su medida justa para obtener un proceso estacionario.

Utilizar la primera opción no sería una buena alternativa ya que su media no tiende a crecer a una tasa constante en el tiempo, véase la constante presente en la figura 1 y en la figura 4 (tal vez no tanto en esta última).

2.1.2 Test de raíces unitarias

Esta familia de test tiene como principal objetivo, detectar la presencia de posibles raíces contenidas dentro del círculo unitario. Es importante la detección de este tipo de raíces ya que esto impacta al realizar nuestras inferencias e incumple el supuesto de estacionariedad, además que en este caso la serie tendrá una variación que acompaña el cambio en el tiempo, los shocks pasados tendrán efectos permanentes y el comportamiento diverge hacia el infinito.

2.1.2.1 Test de Dickey-Fuller tiene como hipótesis nula que el proceso contiene una raíz unitaria y por lo tanto que el proceso es no estacionario, mientras que la alternativa es que no presenta raíz unitaria y por lo tanto, se cumple el supuesto de estacionariedad. Para aplicar este test, se supone un modelo autoregresivo de orden uno, se crean regresiones auxiliares donde se pueden incluir modelos con tendencia determinística o no, de la misma manera que se hace con la incorporación de una constante.

Una consideración importante sobre este test es que se basa en que los ruidos blancos de las regresiones auxiliares no se encuentran correlacionados, en el caso que así sea existen alternativas propuestas por Dickey-Fuller (1979) con un enfoque paramétrico que incluye los rezagos de la variable dependiente.

La ecuación siguiente representa la solución paramétrica de DF (1979), la regresión auxiliar con tendencia determinística es la siguiente:

$$\Delta Y_t = a_0 + a_2 t + \gamma Y_{t-1} + \sum_{j=1}^k \beta_j \Delta Y_{t-j} + \epsilon_t$$

donde Y_t es la serie de tiempo, t es el tiempo, Δ es el operador de diferencia, a_0 y a_2 son los coeficientes de la regresión, γ es el coeficiente de la raíz unitaria, β_j son los coeficientes de los rezagos y ϵ_t es el término de error.

Los contrastes de hipótesis que se realizan son los siguientes:

- Estadístico de prueba, τ_3 contrasta la hipótesis nula de que hay raíz unitaria, contra la alternativa de que no hay raíz unitaria, es decir es un proceso estacionario.

$$\mathbf{H}_0 : \gamma = 0$$

$$\mathbf{H}_1 : \gamma < 1$$

- Estadístico de prueba, ϕ_2 contrasta la hipótesis nula de que no tiene raíz unitaria, constante ni tendencia, contra la alternativa de que una de ellas es distinta de 0.

$$\mathbf{H}_0 : \gamma = a_0 = a_2 = 0$$

$$\mathbf{H}_1 : \text{Al menos uno de ellos es distinto de 0.}$$

- Estadístico de prueba, ϕ_3 contrasta la hipótesis nula de que no tiene raíz unitaria ni tendencia, contra la alternativa de que una de ellas es distinta de 0.

$$\mathbf{H}_0 : \gamma = a_2 = 0$$

$$\mathbf{H}_1 : \text{Al menos uno de ellos es distinto de 0.}$$

El estadístico τ_3 bajo la hipótesis nula sigue una distribución t-Student, mientras que los estadísticos ϕ_2 y ϕ_3 de prueba conjunta siguen una distribución F de Fisher.

Se aplica el test de Dickey-Fuller sobre el logaritmo del gasto público. El test con tendencia y 12 rezagos significativos obtuvo los siguientes resultados para un nivel de significación al 5%. El estadístico $\tau_3 = -2.33$ y un $p - \text{valor} = -3.42$, no se rechaza H_0 y por lo tanto la serie tiene una raíz unitaria. Luego, $\phi_2 = 20.29$ y un $p - \text{valor} = 4.71$, se rechaza H_0 , por lo tanto al menos uno de $\gamma = a_0 = a_2$ es distinto de 0, es decir o presenta constante, o presenta tendencia, porque ya se constrastó que $\gamma = 0$. Por último, $\phi_3 = 3.13$ y un $p - \text{valor} = 6.30$, no se rechaza H_0 , en conclusión la serie no tiene raíz unitaria ni tendencia.

Por lo tanto, dado los 3 contrastes se concluye que la serie tiene raíz unitaria, no tiene tendencia y presenta constante. Esto sugiere que la serie no es estacionaria y se debe de aplicar una diferencia regular para obtener un proceso estacionario.

Se aplica una diferencia regular a la serie dada la sugerencia del test, la figura 6 muestra la evolución de la primera diferencia regular del logaritmo del Gasto Público entre 1999 y 2024. La serie diferenciada presenta una tendencia más estable y menos volátil que la serie original, lo cual sugiere que la diferenciación ha logrado estacionarizar la serie.

$$(1 - L)Ln(gasto)$$




Figura 6: Evolución de la primera diferencia regular del logaritmo del Gasto Público mensual entre 1999 y 2024.

Los nuevos autocorrelogramas pueden verse en la figura 7. En ambas funciones se observa una convergencia, lo cual sugiere que la serie diferenciada es estacionaria.

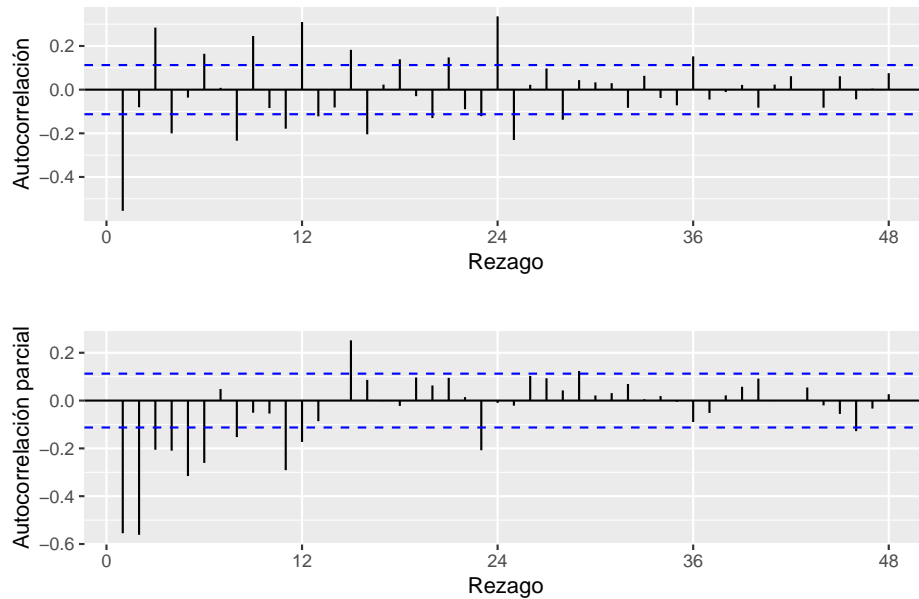


Figura 7: Funciones de Autocorrelación y Autocorrelación Parcial estimadas para la primera diferencia regular del logaritmo del Gasto Público.

Sin embargo, la serie diferenciada presenta una estacionalidad marcada, como se observa en la figura 3, existe una estacionalidad que se repite año a año. En los rezagos 12, 24, 36 de la FAC se ve una significancia, lo cual sugiere que la estacionalidad no ha sido eliminada con la diferenciación regular. Una diferencia estacional anual es aplicada para estacionarizar la serie.

$$(1 - L^{12})\ln(gasto)$$

La figura 13, contenida en el apéndice, contiene la serie con la diferencia estacional. La diferenciación por si sola logra estacionarizar la serie, véase la FAC y FACP en la figura 8.




Figura 8: Funciones de Autocorrelación y Autocorrelación Parcial estimadas para la primera diferencia estacional del logaritmo del Gasto Público (1999-2024).

La diferencia estacional, elimina la estacionalidad presente y logrando convergencia en ambas funciones de autocorrelación, permitiendo estacionarizar la serie. A partir de estos autocorrelogramas, se procede a la identificación de un modelo SARIMA, identificando dos modelos posibles, SARIMA(0,0,1)(0,1,1) y SARIMA(0,0,1)(1,1,0).

Estos modelos surgen de los rezagos significativos presentes en las funciones. Con respecto a la parte regular de modelo, se puede observar una rápida convergencia de la serie en la FAC, mientras que en la FACP dicha convergencia no es tan rápida, lo cual sugiere un modelo que contiene solo parte MA; el rezago 1 significativo de la FAC sugiere $q = 1$ y $p = d = 0$ en un modelo SARIMA(p, d, q)(P, D, Q). Con respecto a la parte estacional, los rezagos múltiplos de 12 son los relevantes en la FAC y FACP, ambas funciones presentan el primer rezago (rezago 12) significativo, y una convergencia medianamente rápida. Esto sugiere probar dos posibilidades $P = 1$ o $Q = 1$ siendo $D = 1$.

Finalmente, se prueban ambas diferencias en la serie, regular y estacional, véase la figura 14 en el apéndice y en la figura 9:

$$(1 - L)(1 - L^{12})Ln(gasto)$$

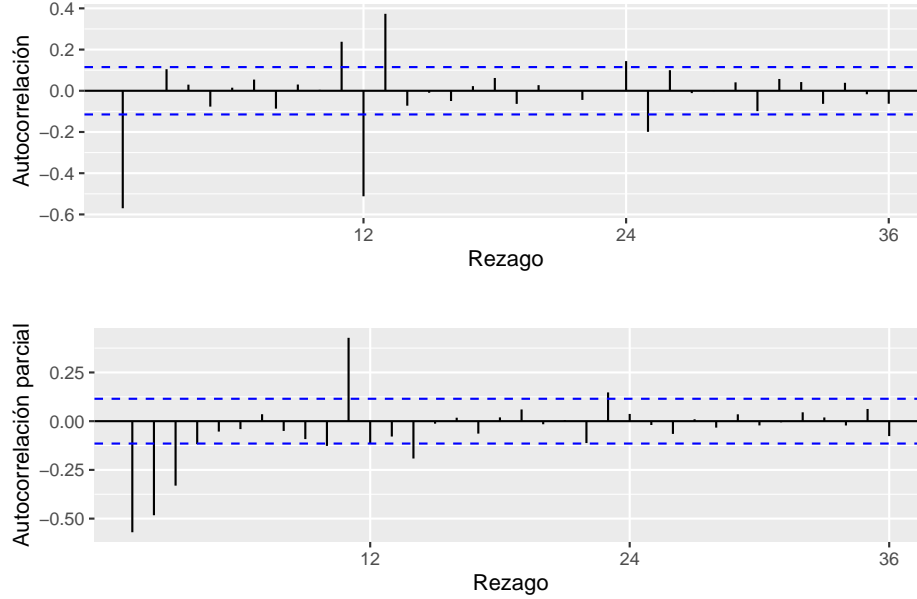


Figura 9: Funciones de Autocorrelación y Autocorrelación Parcial estimadas para la primera diferencia regular de la primera diferencia estacional del logaritmo del Gasto Público.

La convergencia de las funciones es mas consistente que en la serie con diferencia estacional únicamente. A partir de estas funciones se identifican 2 modelos adicionales, SARIMA(0,1,2)(1,1,0) y SARIMA(0,1,1)(0,1,1).

En este caso al haber ambas diferencias los parámetros $d = 1$ y $D = 1$ son fijos. Con respecto a la parte regular, la FACP presenta los primeros tres rezagos significativos, sin embargo se descarta un modelo con parte AR de orden tan grande dado que la FAC no presenta un ruido tan grande; de haber parte AR, la FAC no presentaría una convergencia tan rápida como tiene a partir del rezago 2. En cambio, la convergencia de la FACP es más lenta, lo cual sugiere un modelo con parte MA de orden 1 e incluso 2, por lo tanto $q = 1, 2$. Con respecto a la parte estacional, las conclusiones son las mismas a la de la figura 8, la FAC y la FACP presenta el primer rezago significativo dando lugar a dos posibilidades $P = 1$ o $Q = 1$.

2.2 Estimación del modelo

La etapa de identificación ha identificado 4 modelos posibles para modelar la serie de Gasto Público. Estos modelos son en esta parte estimados y comparados. Adicionalmente es incorporada al modelo una variable regresora, los días de turismo, con el objetivo de capturar

la variabilidad de la serie generada en los marzos y abril de cada año, que coincida con el pago de los aguinaldos de los empleados públicos. La figura 10 representa la evolución del logaritmo del Gasto Público entre enero 2009 y diciembre 2012, con las líneas verticales punteadas marcando los meses de marzo y abril de cada año.




Figura 10: Evolución del Logaritmo del Gasto Público mensual entre enero 2009 y diciembre 2012.

Dependiendo de cuando caen los días de turismo, determina el mes en el que se efectuará el pago de los aguinaldos de los empleados públicos. Esto puede generar un pago anticipado de los aguinaldos en determinado mes, generando un alto gasto, y un gasto mucho menor al mes siguiente. El cuadro 1 muestra los días de turismo de cada año entre 2009-2012:

	2009	2010	2011	2012
Marzo	0	3	0	0
Abril	7	4	7	7

Cuadro 1: Días de turismo en marzo y abril de 2009 a 2012.

Por lo tanto, se incorpora esta variable al modelo para capturar la variabilidad de la serie en los meses de marzo y abril de cada año.

El cuadro 2, es un resumen de la estimación de los 4 modelos SARIMA identificados, proporciona la varianza del modelo y la significancia de sus componentes.

Modelo	SARIMA(p,d,q)(P,D,Q) + turismo	σ^2	Significancia de los componentes
1	(0,0,1)(0,1,1)	0.0493	MA 1 no significativo
2	(0,0,1)(1,1,0)	0.0484	MA 1 no significativo
3	(0,1,2)(1,1,0)	0.0240	Todos significativos
4	(0,1,1)(0,1,1)	0.0271	Todos significativos

Cuadro 2: Estimación de modelos SARIMA.

Los dos modelos que incluyen únicamente la diferencia estacional, aparentan ser peores que los modelos con diferencias regular y estacional en términos de varianza del modelo, a su vez el componente MA de orden 1 en la parte regular de los dos primeros modelos, suele ser rechazada al 5% de nivel de significación.

Este resultado se acompaña del Test de Dickey-Fuller, el cual sugiere que la serie presenta una diferencia regular, y los modelos 1 y 2 no contemplan.

2.3 Diagnóstico

En esta etapa, los 4 modelos estimados son diagnosticados para verificar si cumplen con los supuestos de ruido blanco es decir incorrelación y normalidad de los residuos.

El análisis de las funciones de autocorrelación y autocorrelación parcial de los residuos permite observar la autocorrelación de los mismos, y acompañado del test de Ljung-Box, se verifica la incorrelación.

Por otro lado los tests de Shapiro-Wilks y Jarque-Bera, permiten verificar la normalidad de los residuos.

Las figuras 15, 16, 17, 18 contenidas en el apéndice, muestran los residuos y los residuos estandarizados de los modelos 1, 2, 3 y 4 respectivamente. En todos los casos, los residuos estandarizados presentan observaciones que superan las 3 desviaciones estándar, dando lugar a la presencia de puntos atípicos en todos los modelos que se tienen que intervenir.

Adicionalmente, las figuras 19, 20, 21, 22 contenidas en el apéndice, muestran las funciones de autocorrelación y autocorrelación parcial de los residuos de los modelos 1, 2, 3 y 4 respectivamente. En todos los casos, pueden observarse rezagos significativos lo cual anticipa la ausencia de incorrelación en los residuos. El test de Ljung-Box contrastará esta hipótesis.

Veánse los resultados de la incorrelación y normalidad de los residuos en el cuadro 3.

Modelo	SARIMA(p,d,q)(P,D,Q) + turismo	Incorrelación	Normalidad
1	(0,0,1)(0,1,1)	No	No
2	(0,0,1)(1,1,0)	No	No
3	(0,1,2)(1,1,0)	No	No
4	(0,1,1)(0,1,1)	No	No

Cuadro 3: Diagnostico de modelos SARIMA.

En base al cuadro anterior, podemos ver que todos los modelos rechazan la hipótesis nula, H_0 de Ljung-Box para los primeros 24 rezagos, indicando problemas de ajuste.

De forma similar, todos los modelos presentados tienen problema con la normalidad de los residuos, ya que en absolutamente todos los modelos existe evidencia suficiente para decidir que los residuos no provienen de una distribución normal.

A partir de esto, se procede a detectar e intervenir datos atípicos presentes en la serie, una vez hecho se reestiman los modelos con la inclusión de los outliers detectados. Para la detección de outliers, se utiliza la función `tso` del paquete `tsoutliers`.

Los outliers detectados para cada modelo son las siguientes observaciones:

- Modelo 1
 - AO: 51, 100, 136, 160, 195, 255, 267, 280, 304.
 - LS: 117, 159.
 - TC: 254
- Modelo 2
 - AO: 51, 100, 136, 160, 195, 255, 267, 280, 304.
 - TC: 159, 254, 291.
- Modelo 3
 - AO: 100, 160, 292.
- Modelo 4
 - AO: 51, 100, 136, 160, 195, 255, 268, 279, 292.

Los outliers detectados en cada modelo son en gran parte de tipo aditivo (AO), algunos de ellos se repiten en todos los modelos. El modelo 1 identifica dos casos donde sugiere cambios de nivel (LS), que se corresponden a las fechas 09/2008 y 03/2012, una de estas fechas puede observarse en la figura 10, esta sugerencia en la serie no aparenta ser realmente un cambio de nivel sino tan solo un atípico aditivo. Los modelos 1 y 2 presentan observaciones donde se sugiere atípicos de cambios transitorios (TC). El modelo 3 es el que requiere menor intervenciones con solo 3 outliers detectados correspondientes a las meses de abril de los años 2007, 2012 y 2023, mientras que el modelo 1 es el que requiere mayor intervenciones. Un modelo que requiere menos intervenciones es preferible ante otro con una mayor cantidad de intervenciones.

Los modelos identificados, son reestimados con la inclusión de los outliers detectados. Los resultados de la reestimación se presentan en el cuadro 4.

Modelo	SARIMA(p,d,q)(P,D,Q) + turismo + outliers	σ^2	Significancia de los componentes
1	(0,0,1)(0,1,1)	0.0227	s_MA 1 no significativo
2	(0,0,1)(1,1,0)	0.0226	Todos significativos
3	(0,1,2)(1,1,0)	0.0205	Regresor turismo no significativo
4	(0,1,1)(0,1,1)	0.0156	Todos significativos

Cuadro 4: Reestimación de modelos SARIMA con intervención de outliers.

En base al cuadro anterior, podemos ver que todos los modelos reestimados presentan una varianza del modelo menor que los modelos originales, lo cual es un indicador de un mejor

ajuste. En cuanto a la significancia de los componentes, el modelo 1 presenta un componente MA de orden 1 de la parte estacional no significativo, mientras que el modelo 3 presenta el regresor turismo no significativo.

Se vuelven a reestimar los modelos 1 y 3 con los ajustes mencionados en el parrafo anterior. Una vez modificados se obtienen los resultados presentados en el cuadro 5.

Modelo	SARIMA(p,d,q)(P,D,Q) + outliers	σ^2	Significancia de los componentes
1	(0,0,1)(0,1,0) + turismo	0.0226	Todos significativos
3	(0,1,2)(1,1,0)	0.0205	Todos significativos

Cuadro 5: Reestimación de modelos SARIMA con intervención de outliers.

Se vuelve a estudiar la autocorrelación y normalidad de los residuos de los modelos reestimados. Los resultados se presentan en el cuadro 6.

Modelo	SARIMA(p,d,q)(P,D,Q) + outliers	Incorrelación	Normalidad
1	(0,0,1)(0,1,0) + turismo	No	No
2	(0,0,1)(1,1,0) + turismo	No	No
3	(0,1,2)(1,1,0)	No	No
4	(0,1,1)(0,1,1) + turismo	No	No

Cuadro 6: Diagnosticos de modelos SARIMA.

De forma similar al primer diagnostico, los modelos reestimados presentan problemas de incorrelación y normalidad en los residuos.

En el apéndice, se encuentra la figura 23 que presenta los histogramas de los residuos junto a las densidades de una distribución normal basada en los residuos de cada modelos; en todos los modelos los residuos se asemejan a una distribución normal, sin embargo el test de Shapiro-Wilks rechaza la hipótesis de normalidad.

2.4 Predicción

En esta etapa, se procede a realizar la predicción de la serie Gasto Público. Al momento de realizar una predicción hay cierto puntos que deben tenerse en cuenta antes de comenzar. Primero la función de pérdida asociada, debe ser adecuada al problema que se plantea en particualr. La función de pérdida que se utiliza en esta ocasión es la simétrica, es decir que la penalización de un error de predicción es igual para un error positivo que para un error negativo.

Para graficar la predicción, es utilizado el gráfico de *Fan Chart*, este gráfico permite visualizar la incertidumbre de las predicciones, y reflejar la variabilidad de las predicciones.

El horizonte de predicción seleccionado es a 1 año porque se determinó que la serie tiene cierta estacionalidad anual, dado esto, se considera que el horizonte a un año es un horizonte de predicción adecuado. Por ende se selecciona como conjunto de entrenamiento a las

observaciones hasta abril 2023, dejando al conjunto de mayo 2023 hasta abril 2024 como conjunto de validación.

Se utiliza la función `forecast` del paquete con su mismo nombre para realizar las predicciones.

Para evaluar las predicciones se utiliza las métricas de error absoluto medio (MAE), error absoluto medio porcentual (MAPE) y el error absoluto medio escalado (MASE). Estas métricas permiten evaluar la calidad de las predicciones realizadas en el conjunto de entrenamiento y testeo. El MAE nos dice cuánto se desvía en promedio la predicción del valor real, el MAPE nos dice cuánto se desvía en promedio la predicción del valor real en términos porcentuales y el MASE nos dice la media del error absoluto de las predicciones, escalada por el MAE del conjunto de entrenamiento; para las tres métricas, un valor más cercano a cero indica una mejor predicción.

Las figuras 11 y 12 representan los horizontes de predicción de los modelos 1 y 2, y 3 y 4 respectivamente.

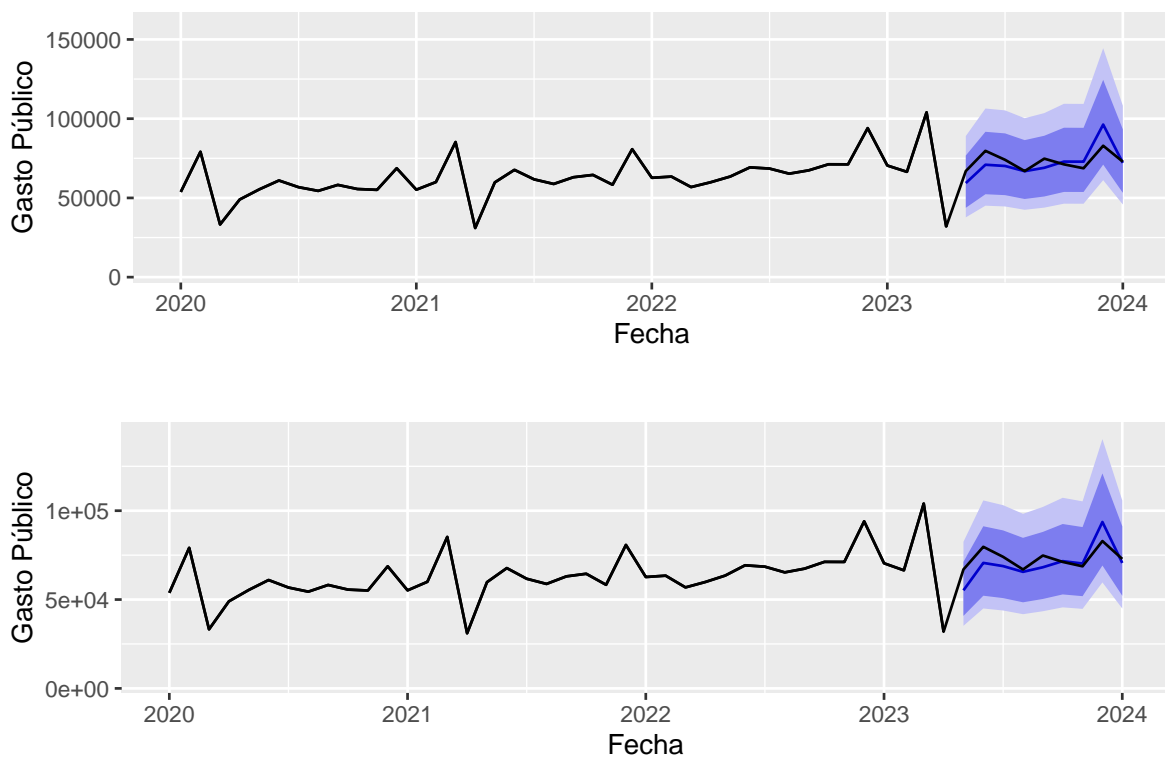


Figura 11: Predicciones en el conjunto de prueba del Gasto Público, para los modelos 1 y 2 respectivamente. La línea azul corresponde a las predicciones y la negra a los datos reales. El azul mas claro corresponde al intervalo de predicción al 95% de confianza y la mas oscura al 80%.

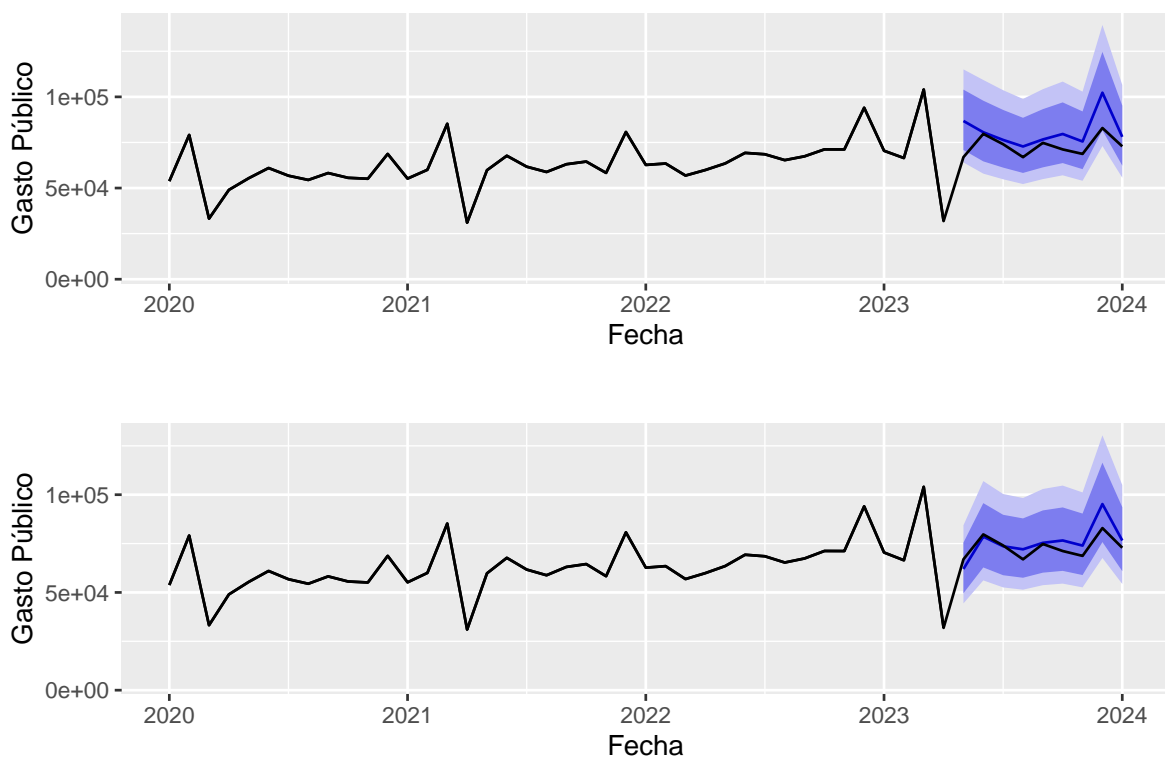


Figura 12: Predicciones en el conjunto de prueba del Gasto Público, para los modelos 3 y 4 respectivamente. La línea azul corresponde a las predicciones y la negra a los datos reales. El azul mas claro corresponde al intervalo de predicción al 95% de confianza y la mas oscura al 80%.

Modelo	Conjunto	MAE	MAPE	MASE
1	Training	3541	12.85	0.868
1	Test	10870	13.98	2.664
2	Training	3565	13.10	0.874
2	Test	9909	12.84	2.429
3	Training	2757	10.92	0.676
3	Test	9333	12.45	2.288
4	Training	2729	10.87	0.669
4	Test	6829	8.93	1.674

Cuadro 7: Resultados de error de predicción para los diferentes modelos.

Las predicciones realizadas en el conjunto de testeo, presentan un error absoluto medio (MAE) de 10870, 9909, 9333 y 6829 para los modelos 1, 2, 3 y 4 respectivamente. El error absoluto medio porcentual (MAPE) es de 13.98, 12.84, 12.45 y 9.42 para los modelos 1, 2, 3 y 4 respectivamente. Y el error absoluto medio escalado (MASE) es de 2.664, 2.429, 2.288 y 1.674 para los modelos 1, 2, 3 y 4 respectivamente. En base a las métricas de error, el

modelo 4 es el que presenta un mejor desempeño en el conjunto de testeo y en el conjunto de entrenamiento para las 3 métricas de error de predicción, seguido por el modelo 3, 2 y 1 respectivamente.

3 Comentarios Finales

En base a los resultados obtenidos, se puede concluir que el modelo 4 (entre los presentados) es el que presenta un mejor desempeño en los datos. Este modelo es un SARIMA(0,1,1)(0,1,1) con un regresor turismo y la inclusión de outliers detectados.

Se ha logrado llegar a resultados positivos, mas alla de la falta de cumplimiento de los supuestos de los residuos respecto a la incorrelación y normalidad de los residuos. Los puntos atípicos presentes en la serie, han sido correctamente identificados y tratados en los modelos, lo cual ha permitido mejorar la calidad de las estimaciones.

Hubiese estado bueno que al identificar los outliers aparte de haber mejorado la estimación, hubiese ayudado al cumplimiento de la incorrelación y normalidad de los residuos.

La predicción realizada en el conjunto de testeo, respondió correctamente, presentando un error de predicción dentro de las expectativas. El modelo 3 presenta una predicción rara de la primer observación que solo queda contenida en el intervalo de predicción al 95% de confianza, se desconoce el motivo de este comportamiento.

A efectos futuros, se sugiere probar las siguientes combinaciones de modelos que quedaron pendientes de estimar y diagnosticar, SARIMA(p,d,q)(P,D,Q):

- (0,1,2) (0,1,1)
- (0,1,1) (1,1,0)

Referencias

Box, G. E. P., G. M. Jenkins, y G. C. Reinsel. 1994. *Time Series Analysis; Forecasting and Control*. 3rd ed. Englewood Cliff, New Jersey: Prentice Hall.

Ministerio de Economía y Finanzas. 2024. «Información y Resultados del Sector Público». <https://www.gub.uy/ministerio-economia-finanzas/datos-y-estadisticas/estadisticas/informacion-resultados-del-sector-publico>.

Apéndice

El informe viene acompañado de 1 carpeta en formato .zip, que contiene todo lo necesario para replicar el trabajo.




Figura 13: Evolución de la primera diferencia estacional del logaritmo del Gasto Público.




Figura 14: Evolución de la primera diferencia regular de la primera diferencia estacional del logaritmo del Gasto Público.




Figura 15: Residuos normales y estandarizados de un modelo SARIMA(0,0,1)(0,1,1) para el logaritmo del Gasto Público.




Figura 16: Residuos normales y estandarizados de un modelo SARIMA(0,0,1)(1,1,0) para el logaritmo del Gasto Público.




Figura 17: Residuos normales y estandarizados de un modelo SARIMA(0,1,2)(1,1,0) para el logaritmo del Gasto Público.




Figura 18: Residuos normales y estandarizados de un modelo SARIMA(0,1,1)(0,1,1) para el logaritmo del Gasto Público.




Figura 19: Funciones de Autocorrelación y Autocorrelación Parcial estimadas de los residuos de un modelo SARIMA(0,0,1)(0,1,1) para el logaritmo del Gasto Público.




Figura 20: Funciones de Autocorrelación y Autocorrelación Parcial estimadas de los residuos de un modelo SARIMA(0,0,1)(1,1,0) para el logaritmo del Gasto Público.




Figura 21: Funciones de Autocorrelación y Autocorrelación Parcial estimadas de los residuos de un modelo SARIMA(0,1,2)(1,1,0) para el logaritmo del Gasto Público.

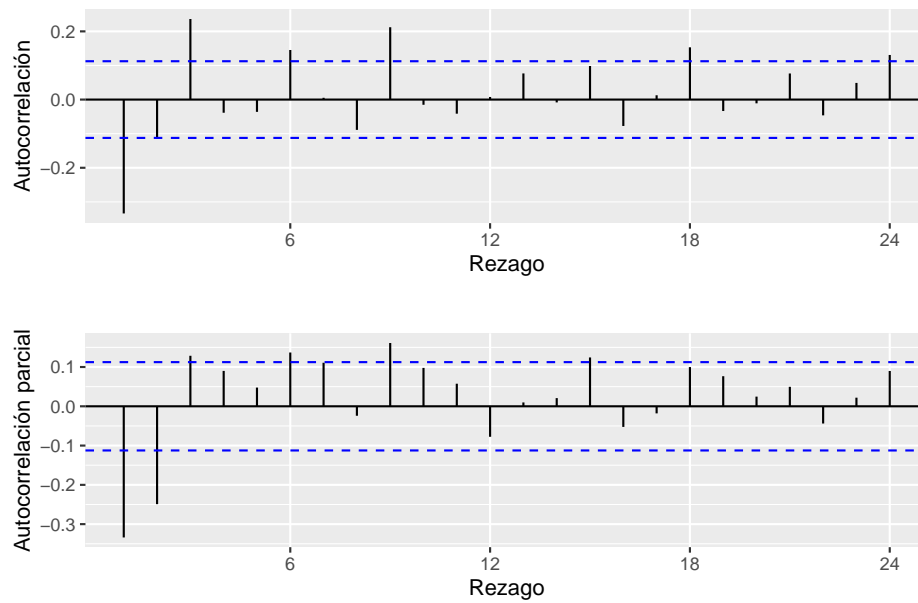


Figura 22: Funciones de Autocorrelación y Autocorrelación Parcial estimadas de los residuos de un modelo SARIMA(0,1,1)(0,1,1) para el logaritmo del Gasto Público.

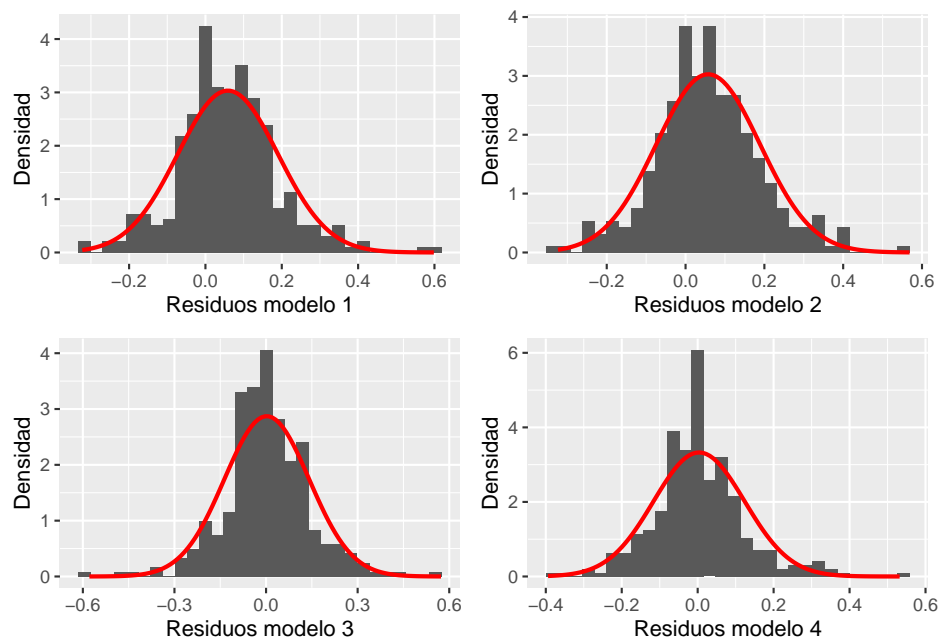


Figura 23: Histograma de los residuos de los modelos reestimados SARIMA intervenido para el logaritmo del Gasto Público. La línea roja corresponde a una densidad normal con media y desvío muestrales igual al de los residuos.